Санкт-Петербургский государственный университет

Математика и механика

Отчёт по учебной практике 2 (научно-исследовательская

работа) (4 семестр)

«Адаптация компактного визуального энкодера и восстановление координат по размеченным парам для межсубъектного поиска изображений по ЭЭГ.»

Выполнил: Хаматьянов М.Р., группа 24.Б44-мм

Подпись:



Научный руководитель:

д. т. н., профессор

Фрадков А.Л.

Кафедра теоретической кибернетики

Подпись:

Работа выполнена полностью, на отличном уровне. Оценка "А". Заслушана на семинаре каф. ТК

Санкт-Петербург 2026

(А.Л. Фрадков)

Содержание

1 Введение **2**

2 Связанные работы **4**
2.1 ЭЭГ энкодер и функция выравнивания 4
2.2 Визуальный энкодер и построение целевого представления . . 5
2.3 Изменение стимула и визуального обучающего сигнала 5
2.4 Геометрия поиска и калибровка участника 6

3 Метод **8**
3.1 ЭЭГ ветвь и общее пространство признаков 8
3.2 Промежуточные визуальные признаки и LoRA 9
3.3 Функции потерь 10
3.4 Грубое и точное выравнивание 13
3.5 Восстановление координат по размеченному опорному набору 14

4 Эксперименты и результаты **17**
4.1 Датасет и протокол оценки 17
4.2 Настройки реализации 18
4.3 Результаты поиска 19
4.4 Визуальная адаптация и модификация SCORE 22

5 Заключение **24**

Литература **26**

1 Введение

Когда человек рассматривает изображение, связанная с этим стимулом нейронная активность изменяется во времени. ЭЭГ измеряет разности потенциалов между электродами на поверхности головы и представляет собой многоканальный временной ряд. Отдельную запись электроэнцефалограммы можно представить в виде матрицы, строки которой соответствуют электродам, а столбцы — отсчётам времени. Это косвенное измерение: каждый электрод регистрирует смесь активности нескольких нейронных источников, а запись также содержит фоновую активность, движения глаз и шум аппаратуры. Поэтому два предъявления одного изображения не дают одинаковых ЭЭГ матриц. Модель должна выделить визуальную информацию, устойчивую к такой изменчивости.

Системы декодирования изображений по ЭЭГ обычно решают одну из двух связанных задач. **Поиск изображений (retrieval)** выбирает исходный стимул из галереи кандидатов. **Генерация** создаёт новое изображение, которое должно напоминать стимул, часто с помощью отдельно обученной генеративной модели. Эта работа посвящена поиску. Получив запись ЭЭГ и 200 изображений-кандидатов, система оценивает каждую ЭЭГ–изображение пару и упорядочивает изображения. Top-1 — доля запросов, для которых исходный стимул занимает первое место; Top-5 — доля запросов, для которых он входит в первые пять. Соответствующие уровни случайного угадывания равны 0.5% и 2.5%. Высокая точность поиска сама по себе не означает, что система сможет синтезировать достоверное изображение.

Чтобы сравнивать ЭЭГ и изображения, их обычно отображают в векторы общего пространства признаков. ЭЭГ энкодер преобразует матрицу потенциалов в ЭЭГ вектор, а визуальный энкодер — каждое изображение-кандидат в визуальный вектор. При обучении представления соответствующих друг другу объектов сближаются, а представления разных стимулов разделяются. На этапе тестирования ранжирование можно строить по косинусному сходству, определяемому углом между векторами. Выбор визуальных признаков существенен: последний слой визуальной модели может

сохранять информацию об идентичности объекта, но отбрасывать детали текстуры или формы, которые ещё отражаются в ЭЭГ. С другой стороны, слишком подробное визуальное представление может требовать информации, которую зашумлённый ЭЭГ сигнал не содержит.

Обобщение проверяется в двух разных аспектах. При тестировании на *невиденных изображениях* тестовые категории изображений отсутствуют в обучении. При тестировании на *невиденном участнике* человек, предоставляющий тестовые ЭЭГ, также не участвует в обучении модели. Второй случай особенно сложен: расположение электродов, анатомия, амплитуда сигнала и шум изменяют систему координат, в которой выражены зрительные ответы человека. Мы обучаем модель на девяти участниках THINGS-EEG2 и оцениваем её на десятом, последовательно исключая каждого из десяти участников.

2 Связанные работы

В декодировании изображений по ЭЭГ по принципу поиска в доступном банке расширение возможностей методов происходит по **четырём направлениям**: изменение стимула или целевого обучающего представления, улучшение ЭЭГ энкодера, изменение визуального энкодера и используемых признаков, а также коррекция геометрии пространства поиска. В реальных системах эти направления пересекаются. Такое деление показывает, какую часть конвейера преимущественно изменяет метод, и не задаёт взаимоисключающих классов подходов.

2.1 ЭЭГ энкодер и функция выравнивания

NICE сформировал практическую базовую модель контрастивного выравнивания ЭЭГ–изображение пар [2]. Его временно-пространственный свёрточный ЭЭГ энкодер преобразует запись ЭЭГ в вектор признаков, а предобученная визуальная модель, прежде всего CLIP в представленных сравнениях, задаёт целевой вектор стимула. Контрастивная функция потерь повышает оценку правильной пары относительно остальных изображений в мини-батче. Так обучается ЭЭГ представление, пригодное для поиска изображений категорий, которые не использовались в качестве обучающих меток. Визуальный энкодер фактически служит учителем: улучшение только ЭЭГ сети может давать ограниченный эффект, если геометрия визуальных признаков плохо соответствует ЭЭГ сигналу.

ATM исследует более выразительное преобразование ЭЭГ, объединяя временную и пространственную обработку с механизмом attention, и использует согласованную с ЭЭГ визуальную информацию для управления диффузионной реконструкцией изображений [3]. Такие изменения могут извлекать больше информации из электродов, однако увеличение ёмкости энкодера также повышает риск запоминания индивидуальных особенностей регистрации вместо активности, связанной со стимулом. Поэтому важно оценивать модель на участнике, который не использовался при её обучении.

2.2 Визуальный энкодер и построение целевого представления

Vision Transformer представляет изображение на нескольких глубинах. Ранние и промежуточные блоки ещё отражают локальную структуру и части объектов, тогда как поздние часто становятся более инвариантными к этим деталям. Shallow Alignment проверяет идею выравнивания ЭЭГ с *промежуточным* представлением вместо автоматического выбора последнего визуального вектора [5]. В работе сравниваются несколько визуальных моделей, включая ViT-B/16 и InternViT, и показано существенное улучшение внутрисубъектных результатов при выборе подходящего промежуточного слоя. Показывая лучшие результаты на модели InternViT.

SAMGA расширяет эту идею: вместо одной выбранной глубины используются несколько взаимодополняющих глубин [6]. Метод проецирует признаки нескольких слоёв замороженного визуального энкодера InternViT-6B [12], содержащего примерно шесть миллиардов параметров, в общее пространство и формирует их взвешенную сумму. При обучении на исходных участниках глобальное предпочтение слоёв корректируется обучаемыми индивидуальными весами; subject dropout делает глобальный маршрут полезным для последующей работы с невиденным человеком. Затем SAMGA выравнивает ЭЭГ и визуальные признаки используя контрастную функцию потерь. Мы сохраняем этот принцип, но заменяем InternViT-6B визуальным ViT-B/16 с примерно 86 миллионами параметров [11,13], то есть приблизительно в семьдесят раз меньшей моделью, и допускаем низкоранговую адаптацию её transformer-блоков. В сохранённых сериях с парным обучением средняя по десяти участникам пиковая Top-1 точность некалиброванного поиска с LoRA сравнима с показателями SAMGA, использующем значительно больший визуальный энкодер, но при этом не применяющий методы дообучения (fine tuning).

2.3 Изменение стимула и визуального обучающего сигнала

Изображение, физически предъявляемое участнику, может содержать детали, которые невозможно надёжно восстановить по сигналу с поверхности головы. Если обучающая цель требует учитывать каждую высокоча-

стотную границу или текстуру, ЭЭГ энкодер должен объяснять различия, которые могут отсутствовать в измеряемом нейронном ответе. UBP уменьшает это несоответствие, оценивая неопределённость ЭЭГ–изображение пары и визуально размывая соответствующее изображение в зависимости от этой оценки [4]. Размытие подавляет мелкие детали визуального обучающего сигнала, позволяя модели сосредоточиться на более доступной для восстановления структуре.

2.4 Геометрия поиска и калибровка участника

Даже хорошо выровненные векторы могут давать низкую точность поиска, если пространство признаков содержит хабы — изображения, похожие сразу на множество ЭЭГ запросов. Cross-domain similarity local scaling (CSLS), предложенный Conneau, Lample, Ranzato et al. для поиска соответствий между словарными векторами разных языков [10], корректирует косинусную оценку, вычитая слагаемые сходства с соседями. Это уменьшает преимущество кандидатов, которые похожи на многие запросы независимо от содержания. Метод изменяет правило ранжирования без переобучения энкодеров. Такая коррекция важна, поскольку высокое исходное косинусное сходство может отражать плотность области пространства представлений, а не только совпадение стимула.

SCORE рассматривает пространство ЭЭГ векторов нового участника как потенциально повёрнутую версию общей визуальной геометрии модели [7]. Сначала метод согласует средние значения и масштабы векторов изображений и записей ЭЭГ, затем выбирает вероятные ЭЭГ–изображение соответствия с помощью CSLS[10] и взаимных ближайших соседей. Важно отметить, SCORE требует доступ к записям ЭЭГ и изображениям из тестовой выборки, при этом информация о том какие записи ЭЭГ относятся к каким изображениям этому методу не требуется. Дальше он оценивает ортогональное преобразование с регуляризацией к единичной матрице чтобы повернуть пространство векторов участника из тестовой выборки так, что-бы оно было более напоминало геометрию пространства векторов обученной модели. Обучение на исходных участниках включает имитацию восстановления координат. Наш вариант этого метода проверяет, может ли

индивидуальная точная информация о связи записей ЭЭГ и изображений, взятая из небольшой подвыборки тренировочных данных, улучшить поиск на тестовой выборке. То есть мы также разворачиваем векторное пространство тестового участника, но матрица будет расчитываться исходя из данных доступных из тренировочной выборки, без нужды обращаться к материалам тестовой выборки. Набор стимульных изображений, взятых из тренировочной выборки, общий для всех участников; меняются только соответствующие записи ЭЭГ (см. из. 3).

3 Метод

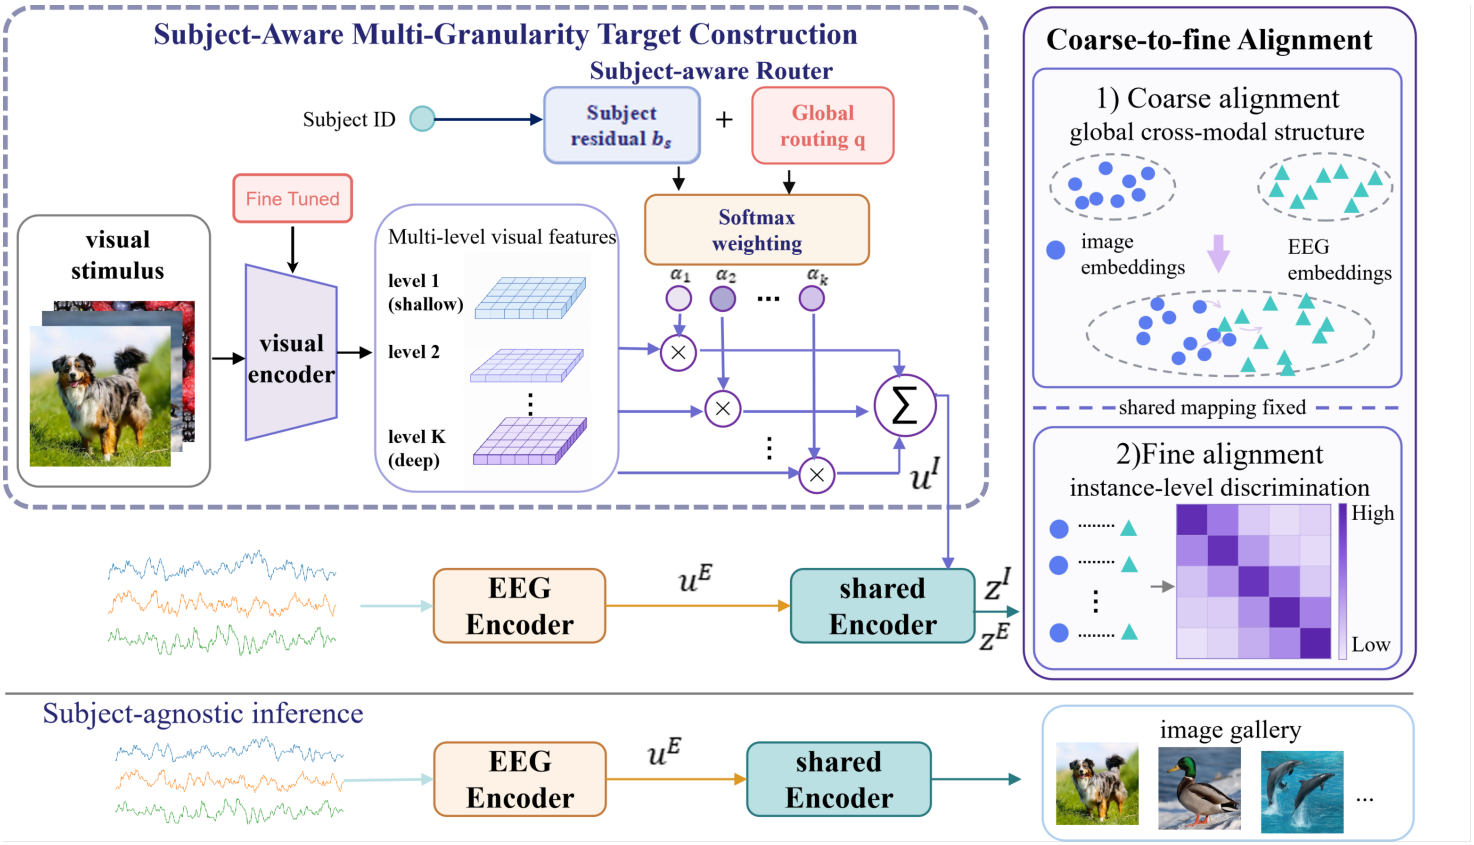


Рис. 1: Индивидуальная маршрутизация визуальных слоёв и поэтапное выравнивание по принципу SAMGA; схема адаптирована из Jiang, She, Xu et al. [6]. Добавленная пометка “Fine Tuned” обозначает адаптацию визуального энкодера с помощью LoRA в нашей реализации. Нижняя ветвь показывает некалиброванный поиск; отдельная калибровка участника представлена на рис. 2.

3.1 ЭЭГ ветвь и общее пространство признаков

Модель отображает ЭЭГ матрицу в пространство признаков, общее с представлениями изображений. ЭЭГ энкодер сохраняет архитектуру TSConv из SAMGA [6]. Временная свёртка выделяет короткие паттерны сигнала на каждом электроде, а временной pooling сжимает последовательность. Следующая пространственная свёртка охватывает ось электродов, благодаря чему каждый выходной канал объединяет информацию с разных участков поверхности головы. После нормализации, активации ELU, dropout и поточечной свёртки карта признаков разворачивается в вектор, обрабатывается остаточной проекцией и передаётся общему энкодеру выравнивания.

Каждое изображение-кандидат отображается в то же пространство. Для ЭЭГ вектора z и визуального вектора v базовой оценкой поиска служит косинусное сходство:

$$\mathrm{sim}(z, v) = \frac{z^{\mathsf{T}} v}{\|z\|_2 \|v\|_2}. \tag{1}$$

3.2 Промежуточные визуальные признаки и LoRA

Наш визуальный энкодер — OpenCLIP ViT-B/16 [11], предобученный на LAION-2B [13]; опубликованная конфигурация SAMGA использует замороженный InternViT-6B [6,12]. ViT-B/16 делит изображение на patches и последовательно обновляет их представления в transformer-блоках; class token агрегирует информацию между patches. Мы берём вектор class token после каждого выбранного промежуточного блока, а не всю последовательность patch tokens и не только выход последнего слоя модели. Эти векторы проходят общую проекцию, а затем отдельные проекции для каждой глубины в общее пространство признаков. Роутер присваивает неотрицательные веса для эмбедингов с каждого слоя, с суммой, равной единице. Взвешенная комбинация проекций становится одним визуальным целевым представлением. Контрастивная функция действует на объединённое представление после общего для ЭЭГ векторов и целевых векторов энкодера. Для одной и той же визуальной модели мы рассматриваем замороженные признаки и вариант с LoRA.

Низкоранговая адаптация (LoRA) изменяет замороженную матрицу весов посредством обучаемой низкоранговой поправки [8]:

$$W_{\text{adapted}} = W + \frac{\alpha}{r} BA. \tag{2}$$

Здесь A и B — обучаемые матрицы с малой внутренней размерностью, r — ранг адаптации, а α задаёт масштаб поправки. В конфигурациях LoRA такие поправки применяются к выбранным проекциям attention и многослойного перцептрона (MLP); также обучаются параметры масштаба и сдвига соответствующих LayerNorm. Исходные матрицы визуального энкодера остаются замороженными, но градиенты проходят через сеть к адаптерам. Конкретная модель, выбранные блоки и настройки адаптации приведены

в разделе экспериментов.

3.3 Функции потерь

Мы рассматриваем и сравниваем два протокола обучения на исходных участниках. Функции потерь SAMGA и модифицированного SCORE используются в отдельных запусках и не объединяются в одну целевую функцию. Их раздельное использование позволяет сохранить исходные формулировки выравнивания соответствующих методов и провести более чистое сравнение. Первый протокол, основанный на SAMGA [6], использует двунаправленный парный поиск по полному мини-батчу. Второй, модифицированный протокол SCORE, использует выравнивание с несколькими положительными соответствиями и дополнительную функцию потерь восстановления по размеченным опорным парам. Пусть мини-батч содержит M ЭЭГ–изображение пар. Для пары i вектор z_i^E представляет запись ЭЭГ после ЭЭГ ветви и общего энкодера, а z_i^I — соответствующее изображение после индивидуальной маршрутизации визуальных признаков и того же общего энкодера. Оба вектора принадлежат общему пространству поиска. При контрастивной температуре τ определим

$$s_{ij} = \frac{\mathrm{sim}(z_i^E, z_j^I)}{\tau}. \tag{3}$$

Парная функция потерь SAMGA. Опубликованная двунаправленная функция поиска SAMGA имеет вид

$$\begin{aligned}
\mathcal{L}_{E\to I} &= -\frac{1}{M}\sum_{i=1}^{M} \log \frac{\exp(s_{ii})}{\sum_{j=1}^{M}\exp(s_{ij})}, \\
\mathcal{L}_{I\to E} &= -\frac{1}{M}\sum_{i=1}^{M} \log \frac{\exp(s_{ii})}{\sum_{j=1}^{M}\exp(s_{ji})}, \\
\mathcal{L}_{\text{ret}} &= \frac{1}{2}\big(\mathcal{L}_{E\to I} + \mathcal{L}_{I\to E}\big).
\end{aligned} \tag{4}$$

Каждое направление повышает оценку соответствующей пары относительно остальных кандидатов полного мини-батча, как в опубликованном коде функции потерь SAMGA.

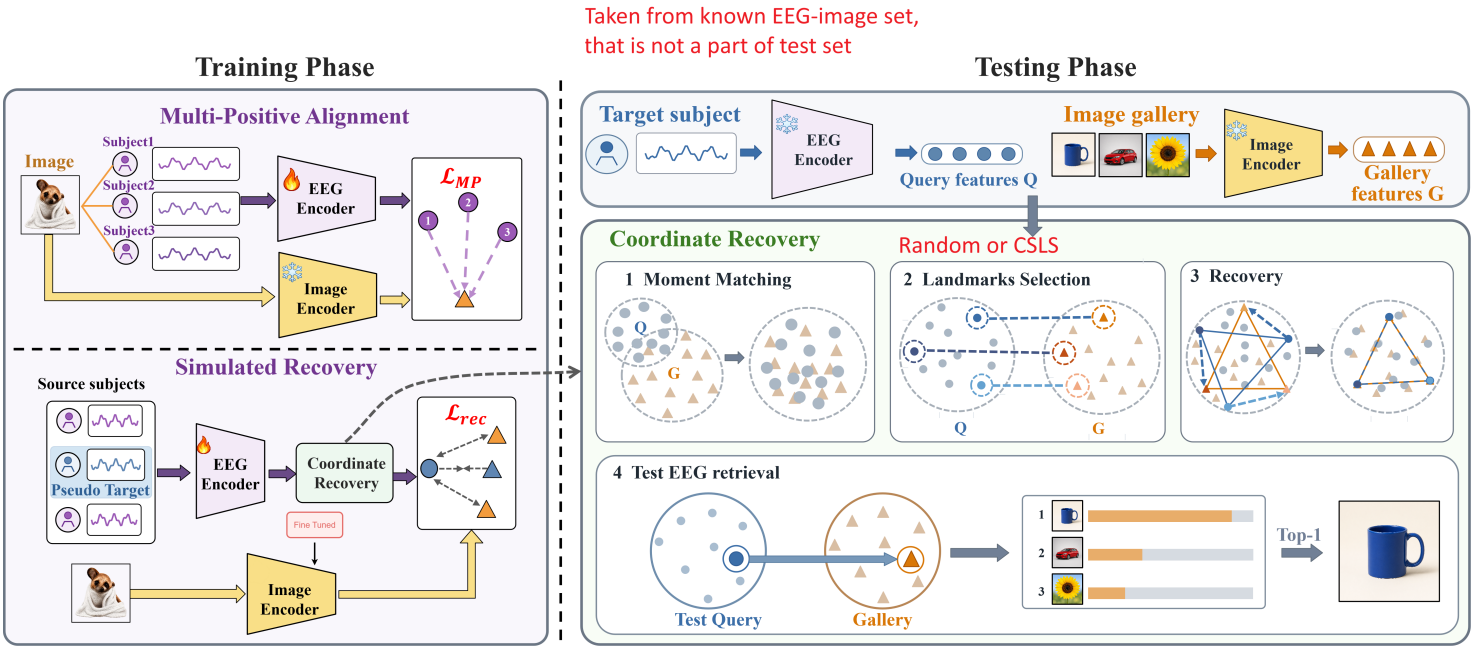


Рис. 2: Обзор обучения и поиска, адаптированный из Cui, Kan, Li et al. [7]; красные подписи обозначают наши изменения протокола SCORE. Левая часть показывает выравнивание с несколькими положительными соответствиями и имитацию восстановления на исходных участниках в модифицированном варианте обучения SCORE (раздел 3.3). Справа согласование моментов и оценка преобразования используют фиксированный набор известных ЭЭГ–изображение калибровочных пар целевого участника, не входящих в тестовый набор; ЭЭГ этого участника не используется для обучения энкодера. Опорные пары выбираются случайно или по CSLS-margin известной пары. Оценённое преобразование применяется к отдельным тестовым ЭЭГ запросам.



Рис. 3: Сравнение протоколов исходного SCORE (слева) и нашего метода (справа). В SCORE преобразование оценивается по неразмеченным тестовым записям ЭЭГ и галерее изображений; в нашем методе — по отдельным размеченным калибровочным парам из тренировочных категорий.

Модифицированная функция потерь SCORE. В этом протоколе все ЭЭГ–изображение пары одного стимульного изображения считаются положительными, как в multi-positive alignment SCORE [7]. Пусть c_i — идентификатор изображения в строке i мини-батча, а $P_i = \{j \in \{1, \dots, M\} : c_j = c_i\}$ — множество строк с тем же изображением. Тогда $|P_i|$ — число положительных соответствий для строки i. Оценка s_{ij} — ЭЭГ–изображение сходство, делённое на τ, как определено выше для SAMGA; индекс k перебирает все M строк-кандидатов в знаменателе. Два направления задаются выражениями

$$\begin{aligned}
\mathcal{L}^{\text{MP}}_{E\to I} &= -\frac{1}{M}\sum_{i=1}^{M}\frac{1}{|P_i|}\sum_{j\in P_i}\log\frac{\exp(s_{ij})}{\sum_{k=1}^{M}\exp(s_{ik})},\\
\mathcal{L}^{\text{MP}}_{I\to E} &= -\frac{1}{M}\sum_{i=1}^{M}\frac{1}{|P_i|}\sum_{j\in P_i}\log\frac{\exp(s_{ji})}{\sum_{k=1}^{M}\exp(s_{ki})},\\
\mathcal{L}_{\text{MP}} &= \mathcal{L}^{\text{MP}}_{E\to I} + \mathcal{L}^{\text{MP}}_{I\to E}.
\end{aligned} \tag{5}$$

Модифицированный протокол SCORE также добавляет эпизод восстановления только на тренировочных участниках. В начале каждой эпохи текущая модель заново выбирает калибровочный набор известных ЭЭГ–изображение пар каждого тренировочного участника. Набор стимульных изображений в этом калибровочном пуле фиксирован и одинаков для всех участников; один и тот же пул используется как для обучения, так и для тестирования модели. Это не создает проблему утечки данных так как в нашем методе калибровочный пул выбирается только как подмножество тренировочного датасета. Опорные пары для оценки преобразования выбираются из калибровочного пула заново в каждой эпохе отдельно для каждого участника с помощью CSLS-margin оценки, аналагично оргинальному методу SCORE. По признакам оцененным на тренировочном батче также заново оцениваются статистики моментов и регуляризованное ортогональное преобразование. В каждом обучающем батче один тренировочный участник временно исключается из обычного выравнивания. Его записи ЭЭГ из текущего батча, не относящиеся к изображениям калибровочного пула, становятся псевдоцелевыми запросами. Оценённое по опорным парам преобразование применяется к их ЭЭГ векторам;

известные соответствующие изображения из тренировочного батча для этого участника используются только для вычисления функции потерь.

Пусть Q — множество индексов псевдоцелевых пар текущего батча, $\hat{z}_i^E$ — вектор z_i^E после восстановления координат по опорным парам (раздел 3.5), а $\tau_{\text{rec}} > 0$ — температура восстановления. Визуальные представления z_j^I в этом эпизоде получены с глобальным маршрутом. Тогда функция потерь для эпизода восстановления координат имеет вид:

$$r_{ij} = \frac{\text{sim}(\hat{z}_i^E, z_j^I)}{\tau_{\text{rec}}},$$
$$\mathcal{L}_{\text{rec}} = -\frac{1}{|Q|} \sum_{i \in Q} \log \frac{\exp(r_{ii})}{\sum_{j \in Q} \exp(r_{ij})}. \tag{6}$$

3.4 Грубое и точное выравнивание

На грубом этапе этапе multi-kernel maximum mean discrepancy (MMD) штрафует различие между *распределениями* представлениями ЭЭГ и визуальных представлений модели. Пусть λ_t — зависящий от эпохи вес MMD, a — масштаб multi-positive alignment, а β — вес восстановления. Обозначим парную конфигурацию через $\mathcal{L}_{\text{P}}$, а модифицированную SCORE-конфигурацию — через $\mathcal{L}_{\text{S}}$. Их функции потерь на грубом этапе имеют вид

$$\mathcal{L}_{\text{P}}^{(t)} = \lambda_t \mathcal{L}_{\text{MMD}} + (1 - \lambda_t)\mathcal{L}_{\text{ret}},$$
$$\mathcal{L}_{\text{S}}^{(t)} = \lambda_t \mathcal{L}_{\text{MMD}} + (1 - \lambda_t) a \mathcal{L}_{\text{MP}} + \beta \mathcal{L}_{\text{rec}}. \tag{7}$$

На точном этапе MMD исключается, а общий энкодер выравнивания замораживается. Парная конфигурация оптимизирует $\mathcal{L}_{\text{ret}}$, а модифицированная SCORE-конфигурация — $a\mathcal{L}_{\text{MP}} + \beta\mathcal{L}_{\text{rec}}$. Визуальные адаптеры обновляются на обоих этапах; конфигурация с замороженным визуальным энкодеромя, добавленная для сравнения результатов, не изменяет его веса. Модифицированная функция SCORE и применение по опорным парам не воспроизводят полный исходный метод SCORE без заранее известных це-

левых меток на тестовом датасете.

3.5 Восстановление координат по размеченному опорному набору

Калибровка добавляет преобразование координат без изменения обученных весов ЭЭГ энкодера и визуального энкодера (см. из. 3). В формуле согласования моментов SCORE (уравнение 3 в [7]) используются обычные деление и умножение, понимаемые отдельно для каждой координаты признаков. Наш вариант, оценивающий статистики только по опорному набору, использует ту же алгебраическую форму для одного ЭЭГ вектора z:

$$\widetilde{z} = \frac{z - \mu_E}{\sigma_E + \varepsilon}(\sigma_I + \varepsilon) + \mu_I. \tag{8}$$

Здесь μ_E, σ_E и μ_I, σ_I — средние значения и стандартные отклонения ЭЭГ и визуальных признаков опорного набора, а ε стабилизирует деление. SCORE оценивает эти моменты по неразмеченному целевому ЭЭГ батчу и галерее изображений. Мы используем отдельные размеченные опорные ЭЭГ–изображение пары с общими для участников изображениями. Этот этап корректирует смещение и разброс, которые невозможно устранить одним ортогональным преобразованием.

Затем из известных пар выбирается подмножество опорных пар. Первый вариант выбирает их равновероятно случайным образом. Второй оценивает, насколько оценка известного правильного изображения выше оценки самого похожего *неправильного изображения из опорного набора*. Для пары i этот margin равен

$$\begin{aligned} m_i = {} & s_{\text{CSLS}}(\widetilde{z}_i, v_i) \\ & - \max_{j \neq i} s_{\text{CSLS}}(\widetilde{z}_i, v_j). \end{aligned} \tag{9}$$

Здесь $\widetilde{z}_i$ — ЭЭГ представление опорной пары после согласования моментов, v_i — её известное правильное визуальное представление, а v_j перебирает остальные изображения опорного набора. Мы сохраняем пары с наибольшими margins. Оба варианта оценивают преобразование одного типа по *заведомо известным* соответствиям. Исходный SCORE, напротив, дол-

жен обнаруживать предполагаемые пары, поскольку не имеет известных таргетов целевого участника на тестовой выборке [7]. Статистики моментов задаёт весь опорный набор, а не только выбранные опорные пары.

Далее выбранные ЭЭГ и визуальные векторы центрируются, и по ним оценивается ортогональное преобразование. Используем обозначения уравнений 6–8 исходного SCORE [7]. Пусть m — число опорных пар, d — размерность общего пространства, а $X, Y \in \mathbb{R}^{m \times d}$ содержат строки соответствующих ЭЭГ признаков после согласования моментов и визуальных признаков. В исходном SCORE диагональная матрица $W = \mathrm{diag}(w_1, \ldots, w_m)$ задаёт веса уверенности опорных пар. В нашей реализации все выбранные пары имеют одинаковый вес: $w_i = 1$, поэтому $W = I_m$. Далее единичная матрица W опускается в уравнениях, а центры вычисляются как обычные средние. CSLS-margin используется только для отбора пар.

Их центры и центрированные матрицы равны

$$\begin{aligned} \mu_X &= \frac{1}{m} \sum_{i=1}^{m} X_{i,:}, \\ \mu_Y &= \frac{1}{m} \sum_{i=1}^{m} Y_{i,:}, \\ \widetilde{X} &= X - \mathbf{1}_m \mu_X, \\ \widetilde{Y} &= Y - \mathbf{1}_m \mu_Y. \end{aligned} \tag{10}$$

Здесь $\mathbf{1}_m$ — столбец из m единиц; центры записаны как строки.

Ортогональное преобразование оценивается решением ортогональной задачи Прокруста с регуляризацией к единичной матрице:

$$\begin{aligned} R^\star = \underset{R^\top R = I_d}{\arg\min} \Big[&\big\| \widetilde{X} R - \widetilde{Y} \big\|_F^2 \\ &+ \lambda \big\| R - I_d \big\|_F^2 \Big]. \end{aligned} \tag{11}$$

Первое слагаемое уменьшает несовпадение преобразованных ЭЭГ векторов опорных пар с соответствующими визуальными векторами. Второе штрафует отклонение от единичного преобразования I_d. Норма Фробениуса задаётся суммой квадратов всех элементов: $\|A\|_F^2 = \sum_{a,b} A_{ab}^2$. Условие

$R^\top R = I_d$ допускает поворот или отражение, но не произвольное растяжение пространства. Сила регуляризации масштабируется как в SCORE:

$$\lambda = \rho \left\| \widetilde{X}^\top \widetilde{Y} \right\|_2. \tag{12}$$

Здесь $\rho \geq 0$ — безразмерный параметр, а спектральная норма матрицы $\| \cdot \|_2$ равна её наибольшему сингулярному значению. При $m < d$ опорные пары не определяют все направления пространства, и регуляризация поддерживает близость недостаточно определённых направлений к исходным координатам.

При ортогональном R квадратичная задача эквивалентна максимизации следа:

$$\begin{aligned} R^\star &= \underset{R^\top R = I_d}{\arg\max}\ \operatorname{tr}(R^\top M), \\ M &= \widetilde{X}^\top \widetilde{Y} + \lambda I_d. \end{aligned} \tag{13}$$

Если SVD-разложение имеет вид $M = U\Sigma V^\top$, замкнутое решение в рамках задачи Прокруста равно

$$R^\star = UV^\top. \tag{14}$$

Для нового ЭЭГ запроса после согласования моментов применяются те же центры и найденная матрица:

$$z' = (\widetilde{z} - \mu_X)R^\star + \mu_Y. \tag{15}$$

Моменты, центры и преобразование оцениваются заново для текущего checkpoint на каждой оценочной эпохе, затем фиксируются для обработки её тестовых запросов. Один новый запрос не использует другие тестовые записи ЭЭГ.

Наконец, невиденные тестовые изображения ранжируются по косинусному сходству или CSLS. CSLS вычитает слагаемые сходства с соседями, снижая преимущество концентрированных хабов в пространстве представлений.

4 Эксперименты и результаты

4.1 Датасет и протокол оценки

THINGS-EEG2 содержит вызванные зрительными стимулами записи ЭЭГ десяти участников, рассматривавших большой набор фотографий объектов [1]. Обучающий раздел включает 1 654 категории объектов по десять разных изображений в каждой; тестовый раздел — 200 других категорий по одному изображению. Обучающее изображение предъявлялось четыре раза, тестовое — 80 раз. В локальных массивах повторения одного изображения усредняются отдельно для каждого участника, в результате остаются 16 540 обучающих и 200 тестовых записей ЭЭГ на человека. Усреднение повышает отношение сигнал/шум, поэтому эксперименты оценивают поиск по одной *записи ЭЭГ, усреднённой по повторным предъявлениям изображения*, а не декодирование после единственного предъявления.

Предобработка следует общему протоколу NICE: непрерывный ЭЭГ программно фильтруется в полосе 0.1–100 Гц, соответствующей указанной в SAMGA [6]; эпохи охватывают 0–1000 мс после начала стимула, предшествующие 200 мс используются для коррекции baseline, сохраняются все 63 электрода, а частота дискретизации снижается до 250 Гц [2]. Multivariate noise normalization (MVNN) представляет собой пространственный метод выбеливания (whitening): внутри каждой сессии оценки ковариации каналов по обучающим эпохам усредняются, затем вычисляется обратный квадратный корень полученной матрицы и применяется к обучающим и тестовым эпохам. Вход модели имеет размер 63×250.

Мы используем leave-one-subject-out оценку. Модель обучается на девяти исходных участниках; десятый не участвует в градиентном обучении модели. Процедура повторяется десять раз, чтобы каждый участник один раз оказался целевым. Тестовые категории изображений не пересекаются с обучающими, поэтому тестирование проверяет перенос как на новые категории, так и на нового участника. При оценке каждая из 200 записей ЭЭГ целевого участника ранжируется относительно 200 тестовых изображений. Для кодирования изображения галереи соответствующая ему за-

пись ЭЭГ не нужна.

Калибровочный протокол отделён от тестовой галереи (см. из. 3). При фиксированном seed в конфигурации обучения модели выбирается число обучающих категорий изображений и одно изображение каждой категории. Полученные изображения составляют калибровочный пул. Пул изображений одинаков для всех участников. В стадии тестирования мы достаем калибровочный пул изображений и соответствующие записи ЭЭГ человека на котором происходит тестирование, на этих данных расчитывается сдвиг и матрица поворота для пространства представлений участника; тестовые записи ЭЭГ и их истинные соответствия не используются для оценки преобразования. Опорные изображения сохраняются в обычном обучении на исходных участниках.

4.2 Настройки реализации

ЭЭГ энкодер использует 40 временных фильтров с ядром длиной 25 отсчётов. Развёрнутая карта признаков проходит остаточное представление размерности 1 024 и отображается в общее 512-мерное пространство поиска. Визуальный энкодер — OpenCLIP ViT-B/16, предобученный на LAION-2B [11,13], примерно с 86 миллионами параметров, patches размера 16×16 и 12 transformer-блоками. Мы извлекаем состояния class token из блоков 3, 5, 7 и 9. Общая проекция расширяет каждый 768-мерный вектор до 1 024 измерений; отдельные проекции слоёв затем дают 512-мерные представления для индивидуального роутера. В отличие от замороженного InternViT в SAMGA [6,12], конфигурации LoRA адаптируют компактный визуальный энкодер во время обучения на исходных участниках; замороженная конфигурация использует заранее вычисленные признаки тех же слоёв.

В адаптируемых конфигурациях LoRA имеет ранг $r = 192$ и масштаб $\alpha = 16$ в блоках 3–9. Адаптация охватывает query, key, value и output projections механизма attention, а также обе проекции MLP. Параметры масштаба и сдвига соответствующих LayerNorm также обучаются. LoRA активна на обоих этапах обучения. Грубое и точное выравнивание длятся по 15 эпох. Для сокращения затрат на визуальное кодирование каждый исходный батч выбирает 100 разных изображений и включает по одной записи ЭЭГ каж-

дого из девяти обучающих участников для каждого изображения, то есть до 900 ЭЭГ–изображение строк. Опубликованная функция потерь SAMGA работает с полной матрицей сходств этих строк и диагональными парами в качестве правильных соответствий. Learning rate визуальных адаптеров равен 10^{-4}. Каждое уникальное изображение требует одного прямого прохода live ViT; gradient caching повторно кодирует визуальный microbatch при обратном распространении. Замороженная конфигурация читает заранее вычисленные признаки того же энкодера.

Три сохранённые серии используют одинаковую ЭЭГ архитектуру, выбранные глубины визуальных признаков, номинальное расписание обучения, опорный набор и код оценки. Две серии используют парное ЭЭГ–изображение обучение: с визуальной LoRA и без неё. Третья использует модифицированную функцию SCORE с масштабом выравнивания $a = 1$, весом восстановления $\beta = 0.2$ и температурой восстановления 0.07. Для каждого исходного участника 200 размеченных опорных изображений задают моменты признаков, а 150 известных пар, выбранных по CSLS-margin, используются для оценки регуляризованного преобразования с $\rho = 0.13$. Случайный отбор отдельно оценивается при применении.

При калибровке целевого участника все 200 размеченных опорных пар задают средние значения и стандартные отклонения признаков. Для оценки ортогонального преобразования с $\rho = 0.13$ используются либо 150 случайных пар, либо 150 пар с наибольшими CSLS-margins известных правильных соответствий. Мы оцениваем некалиброванные представления и оба калиброванных варианта с cosine и CSLS-ранжированием по фиксированному опорному ЭЭГ набору. В результате для каждого исключённого участника получаются шесть условий поиска.

4.3 Результаты поиска

Оценка показывает, насколько точно можно найти изображения невиденного участника без калибровки, как отдельный размеченный опорный набор изменяет поиск и чем отличаются сохранённые конфигурации обучения. Некалиброванные строки cosine и CSLS отвечают на первый вопрос, а строки со случайным и CSLS-отобранным преобразованием — на второй.

Таблица 1 объединяет три локальные серии; для каждого режима поиска R@1 и R@5 приведены соседними строками.

S_1–S_{10} обозначают исключённого участника. Все значения — проценты на галерее из 200 изображений. Источники из литературы используют собственные процедуры выбора модели и повторения по seed: Shallow Alignment и SAMGA сообщают средние по пяти запускам [5,6], а SCORE — общее среднее по трём seed на последней эпохе [7]. Каждая локальная ячейка для участника, режима и метрики — максимум по сохранённым тестовым эпохам соответствующего запуска. Все три серии содержат десять завершённых запусков по 30 эпох. В основной статье SCORE точные численные результаты каждого участника не приведены, поэтому эти ячейки обозначены NR и не оценивались по рисунку.

Таблица 1: Top-1 и Top-5 точность поиска для исключённого участника (%). Локальные строки включают три завершённые серии обучения; парная серия с LoRA обновлена по запускам от 1 октября 2026 года.

Метод	Метрика	S1	S2	S3	S4	S5	S6	S7	S8	S9	S10	Среднее S1–S10
Опубликованные результаты												
Shallow ViT-B/16 [5]	Top-1	18.3	23.7	7.4	17.8	14.1	12.1	14.4	15.0	17.6	22.7	16.3
	Top-5	42.8	52.1	26.3	45.1	40.0	39.3	38.4	36.1	46.1	54.7	42.1
Shallow InternViT [5]	Top-1	23.5	30.6	10.0	19.5	18.1	22.7	18.6	17.3	23.0	34.4	21.8
	Top-5	53.2	60.4	28.1	48.3	45.2	49.8	46.0	46.1	54.8	62.0	49.4
SAMGA InternViT [6]	Top-1	36.3	42.2	24.7	34.0	30.0	35.2	35.1	28.7	28.1	49.6	34.4
	Top-5	69.8	71.7	50.7	66.7	64.3	67.7	61.0	59.5	57.0	79.4	64.8
SCORE + SAMGA [7]	Top-1	NR	NR	NR	NR	NR	NR	NR	NR	NR	NR	53.2
	Top-5	NR	NR	NR	NR	NR	NR	NR	NR	NR	NR	83.5
Наше парное обучение SAMGA, ViT-B/16 с LoRA: 1 октября 2026 года												
Без калибровки / cosine	Top-1	47.0	38.0	22.0	33.0	28.0	38.0	30.0	30.5	26.0	51.0	34.4
	Top-5	81.5	73.0	52.5	65.5	62.5	66.0	63.5	64.5	57.0	87.5	67.4
Без калибровки / CSLS	Top-1	50.0	43.0	24.5	34.0	33.0	40.5	35.0	32.5	30.5	57.5	38.1
	Top-5	83.0	77.0	55.0	67.5	70.0	68.0	67.0	67.5	64.5	92.0	71.2
Случайные пары / cosine	Top-1	52.0	46.5	41.5	40.0	43.5	43.0	48.5	38.0	39.0	59.5	45.2
	Top-5	83.5	81.5	80.0	73.0	82.0	76.0	82.0	68.5	75.5	91.0	79.3
Случайные пары / CSLS	Top-1	54.0	54.5	45.5	40.5	45.5	45.0	51.5	41.0	43.5	65.5	48.7
	Top-5	86.0	85.0	80.5	77.0	82.0	77.0	82.5	71.0	76.5	92.5	81.0
CSLS-отбор / cosine	Top-1	54.0	47.0	43.0	38.0	43.0	43.0	48.0	37.0	40.0	59.5	45.3
	Top-5	85.5	80.0	76.5	72.5	79.5	75.0	80.0	69.5	73.5	92.0	78.4
CSLS-отбор / CSLS	Top-1	58.0	52.0	41.5	40.5	45.0	44.0	50.0	40.5	46.0	65.0	48.3
	Top-5	87.5	83.5	78.5	76.5	82.0	78.5	82.0	72.5	77.5	93.0	81.2
Наше парное обучение, замороженный ViT-B/16												
Без калибровки / cosine	Top-1	24.5	21.5	18.5	20.5	18.5	25.0	18.0	17.5	18.0	28.0	21.0
	Top-5	54.0	53.0	50.0	50.5	41.5	54.0	45.5	42.0	40.5	64.5	49.6
Без калибровки / CSLS	Top-1	24.5	28.0	20.0	21.5	19.5	30.0	22.5	18.0	20.5	33.5	23.8
	Top-5	55.0	58.0	52.5	51.5	48.0	60.5	46.5	45.0	43.5	65.0	52.6
Случайные пары / cosine	Top-1	27.5	32.0	22.5	27.5	22.5	29.5	24.0	22.5	25.0	29.0	26.2
	Top-5	58.5	62.5	56.5	59.0	51.0	58.5	51.0	50.0	52.0	66.0	56.5
Случайные пары / CSLS	Top-1	26.5	32.5	25.0	27.5	23.5	31.5	26.0	23.5	26.5	33.0	27.6
	Top-5	59.5	66.5	57.0	60.5	55.0	63.0	52.0	50.5	53.5	68.0	58.6
CSLS-отбор / cosine	Top-1	26.5	30.0	22.0	23.5	23.0	30.0	24.0	22.0	25.5	29.0	25.6
	Top-5	60.0	62.0	55.0	57.5	48.0	60.0	50.5	50.0	49.5	65.5	55.8
CSLS-отбор / CSLS	Top-1	27.5	31.0	24.5	26.0	24.0	32.0	26.5	22.5	27.0	33.5	27.5
	Top-5	61.5	64.0	57.0	60.0	53.0	64.0	51.5	53.0	52.0	67.0	58.3
Наше модифицированное обучение SCORE, ViT-B/16 с LoRA												
Без калибровки / cosine	Top-1	35.0	33.5	17.0	31.5	25.0	34.0	33.5	28.0	27.5	51.5	31.7
	Top-5	69.0	69.0	45.5	68.5	58.5	68.5	66.0	61.5	55.5	85.5	64.8
Без калибровки / CSLS	Top-1	36.5	37.0	18.5	33.5	28.5	38.0	38.5	29.0	30.5	57.5	34.8
	Top-5	71.0	71.5	51.5	69.5	62.0	70.5	70.5	63.5	58.5	88.0	67.7
Случайные пары / cosine	Top-1	38.5	38.5	33.5	31.5	30.5	40.5	44.0	36.0	33.0	57.0	38.3
	Top-5	76.0	72.0	64.0	67.0	69.5	73.0	74.0	66.0	67.5	89.5	71.9
Случайные пары / CSLS	Top-1	44.5	44.0	35.5	35.5	34.5	42.5	47.0	37.5	38.5	59.0	41.9
	Top-5	79.5	79.0	67.5	71.0	75.0	76.0	78.5	70.5	71.5	91.5	76.0
CSLS-отбор / cosine	Top-1	40.0	36.0	34.0	33.5	31.0	38.5	43.0	34.0	32.0	58.5	38.1
	Top-5	73.5	73.5	66.0	68.5	71.0	72.0	74.5	67.5	63.5	89.5	72.0
CSLS-отбор / CSLS	Top-1	43.0	41.0	35.0	35.0	38.0	39.5	45.5	36.0	35.5	61.5	41.0
	Top-5	78.0	80.0	68.0	72.0	72.5	75.5	78.0	70.5	69.5	91.0	75.5

NR — точные численные значения по участникам не приведены в SCORE [7]. Источники опубликованных строк: Shallow Alignment, таблица 5 приложения [5]; SAMGA, таблица 2 [6]; SCORE, таблица 2 [7]. Локальные значения — максимумы по сохранённым тестовым эпохам отдельно для каждого участника и каждой метрики, поэтому Top-1 и Top-5 могут относиться к разным эпохам. Каждая локальная серия содержит десять завершённых запусков по 30 эпох. S1–S10 обозначает среднее по всем десяти участникам. Парные результаты с LoRA взяты из запусков от 1 октября 2026 года с программной фильтрацией ЭЭГ в полосе 0.1–100 Гц. Замороженная и модифицированная SCORE-серии сохранены из запусков 30 сентября и 29–30 сентября соответственно. Опубликованные и локальные результаты различаются протоколами и правилами выбора checkpoint.

4.4 Визуальная адаптация и модификация SCORE

Основной результат — в парной LoRA-серии от 1 октября средняя по десяти участникам пиковая Top-1 точность некалиброванного cosine-поиска достигает 34.4%. Это совпадает с опубликованным результатом SAMGA (34.4%) [6]. При этом наш OpenCLIP ViT-B/16 содержит около 86 миллионов параметров, тогда как замороженный InternViT-6B в SAMGA — около шести миллиардов. Сопоставимая Top-1 точность достигается с помощью адаптации визуального энкодера, который приблизительно в семьдесят раз меньше по числу параметров.

Сравнение с сохранённой серией без визуальной адаптации показывает масштаб различия: средняя пиковая Top-1 точность некалиброванного cosine-поиска составляет 21.0% для замороженного ViT-B/16 и 34.4% для варианта с LoRA; соответствующие Top-5 значения равны 49.6% и 67.4%. При случайном отборе опорных пар и CSLS-поиске средние Top-1 значения составляют 27.6% и 48.7%, а Top-5 — 58.6% и 81.0%. Эти результаты согласуются с полезностью визуального дообучения, хотя серии различаются также предобработкой и потому не изолируют вклад одной LoRA.

Второе направление экспериментов — наша модификация применения SCORE: преобразование оценивается по отдельному набору размеченных калибровочных пар, а не по тестовым записям ЭЭГ. В парной LoRA-серии преобразование по случайным опорным парам вместе с CSLS-поиском даёт 48.7% Top-1 и 81.0% Top-5. По неокруглённым средним это на 14.3 и 13.7 процентного пункта выше некалиброванного cosine-поиска. Прибавка объединяет согласование моментов, ортогональное преобразование и изменение ранжирования; она характеризует весь калиброванный протокол, а не только индивидуальный поворот.

Отдельно влияние ранжирования видно в некалиброванных результатах: переход от cosine к CSLS по фиксированному ЭЭГ набору повышает среднюю пиковую Top-1 точность с 34.4% до 38.1%, а Top-5 — с 67.4% до 71.2%. Для этого не требуется переобучать энкодеры или оценивать индивидуальное ортогональное преобразование. Таблица 1 также позволяет сравнить случайное преобразование с cosine и некалиброванный cosine-

поиск, чтобы оценить калибровку при фиксированном правиле ранжирования, а затем сравнить cosine и CSLS после одной и той же процедуры калибровки.

Отбор 150 опорных пар по CSLS-margin известной пары не повышает среднюю Top-1 точность парной LoRA-серии относительно случайного отбора. При CSLS-отборе и CSLS-поиске средние составляют 48.3% Top-1 и 81.2% Top-5, при случайном отборе — 48.7% и 81.0%. Различие имеет разные направления для двух метрик: преимущество CSLS-margin отбора одновременно по Top-1 и Top-5 в этой конфигурации не наблюдается.

Изменение точности после калибровки различается между участниками. Для участника 3 Top-1 пик увеличивается с 22.0% при некалиброванном cosine-поиске до 45.5% со случайным преобразованием и CSLS. Участник 10 показывает 51.0% без калибровки и достигает 65.5% с тем же калиброванным протоколом. Как и остальные локальные результаты, эти значения являются максимумами, выбранными отдельно по тестовым эпохам.

Наконец, замена парной целевой функции на модифицированное обучение SCORE снижает средние результаты по всем десяти общим участникам во всех представленных режимах поиска. Top-1 некалиброванного cosine-поиска составляет 34.4% для парной LoRA-серии и 31.7% для SCORE-серии. При случайном преобразовании и CSLS средняя Top-1 точность равна 48.7% и 41.9%, а Top-5 — 81.0% и 76.0% соответственно. Multi-positive alignment и восстановление были включены совместно; серии различаются также предобработкой, а результаты выбраны независимо по лучшим тестовым эпохам. Поэтому снижение характеризует всю проверенную конфигурацию и не определяет вклад отдельного компонента модифицированной функции потерь.

5 Заключение

Основное наблюдение состоит в том, что отдельный размеченный опорный набор может заметно изменить ранжирование для нового участника без градиентного обновления энкодеров. Это согласуется с предположением, что ЭЭГ представления целевого человека занимают смещённую или повёрнутую систему координат относительно общих визуальных представлений. Центрированное ортогональное преобразование специально ограничено: оно не создаёт произвольные нелинейные признаки и не растягивает отдельные координаты. Если улучшение сохранится при строгом выборе модели, это поддержит изучение индивидуальной геометрии, а не только наращивание ёмкости ЭЭГ сети. Текущее сравнение одновременно включает согласование моментов, оценку преобразования и CSLS, поэтому пока не определяет отдельный вклад каждого компонента.

Сравнение компактного визуального энкодера с опубликованным SAMGA показывает перспективность адаптации. Сохранённые парные серии используют одинаковую ЭЭГ модель, глубины визуальных признаков и номинальное расписание, а их средние Top-1 пики некалиброванного cosine-поиска различаются на 13.4 процентного пункта. ViT-B/16 существенно меньше InternViT-6B, и его результат с адаптацией (34.4%) близок к опубликованному среднему SAMGA по пяти seed (34.4%). Это указывает, что дообучение компактного визуального энкодера может давать существенное улучшение поиска и достигать точности, сопоставимой с гораздо более крупным замороженным энкодером. Сравнение с литературой не является контролируемым экспериментом по размеру модели; дополнительное различие предобработки локальных серий также ограничивает причинный вывод о LoRA.

Наши результаты калибровки указывают, что индивидуальная ЭЭГ–изображение связь, оценённая по известным парам, может улучшать поиск отдельных невиденных тестовых изображений. Преобразование оценивается по фиксированному набору размеченных калибровочных стимулов, общих для всех исключённых участников, и затем применяется к тестовым ЭЭГ по одному. Исходный SCORE оценивает статистики

и предполагаемые ЭЭГ–изображение соответствия по неразмеченному набору целевых запросов и галерее кандидатов; его преобразование не использует известные пары целевого участника и оценивается на этом наборе запросов [7]. Полный опубликованный SCORE сообщает 53.23% Top-1 и 83.55% Top-5 в своём протоколе; наша обновлённая парная LoRA-серия даёт 48.7% и 81.0% средних пиков со случайным преобразованием и CSLS. Прямое сравнение ограничено различием информации для оценки преобразования и протоколов поиска. Полученные результаты позволяют предположить, что локальная геометрия представлений ЭЭГ в тестовой выборке может быть более информативной для оценки адаптирующего поворота и сдвига, чем геометрическая связь представлений ЭЭГ с соответствующими представлениями изображений, оценённая по размеченным парам из тренировочной выборки.

Литература

[1] Alessandro T. Gifford, Kshitij Dwivedi, Gemma Roig, et al. (2022). A large and rich EEG dataset for modeling human visual object recognition. NeuroImage 264, 119754.

[2] Yonghao Song, Bingchuan Liu, Xiang Li, et al. (2024). Decoding Natural Images from EEG for Object Recognition (NICE). arXiv:2308.13234.

[3] Dongyang Li, Chen Wei, Shiying Li, et al. (2024). Visual Decoding and Reconstruction via EEG Embeddings with Guided Diffusion (ATM). arXiv:2403.07721.

[4] Haitao Wu, Qing Li, Changqing Zhang, et al. (2025). Bridging the Vision-Brain Gap with an Uncertainty-Aware Blur Prior. CVPR 2025.

[5] Yang Du, Siyuan Dai, Yonghao Song, et al. (2026). Deep Models, Shallow Alignment: Uncovering the Granularity Mismatch in Neural Decoding. arXiv:2601.21948.

[6] Lin Jiang, Qingshan She, Jiale Xu, et al. (2026). Subject-Aware Multi-Granularity Alignment for Zero-Shot EEG-to-Image Retrieval. arXiv:2604.17782.

[7] Zhenyao Cui, Siyuan Kan, Siyang Li, et al. (2026). SCORE: Subject Coordinate Recovery for Label-Free Cross-Subject EEG-to-Image Retrieval. arXiv:2608.19134.

[8] Edward J. Hu, Yelong Shen, Phillip Wallis, et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685.

[9] Wenjiang Zhang, Sifeng Wang, Yuwei Su, et al. (2026). NeuroBridge: Bio-Inspired Self-Supervised EEG-to-Image Decoding via Cognitive Priors and Bidirectional Semantic Alignment. AAAI 2026.

[10] Alexis Conneau, Guillaume Lample, Marc'Aurelio Ranzato, et al. (2018). Word Translation Without Parallel Data. ICLR 2018, arXiv:1710.04087.

[11] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, et al. (2021). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. ICLR 2021, arXiv:2010.11929.

[12] Zhe Chen, Jiannan Wu, Wenhai Wang, et al. (2024). InternVL: Scaling up Vision Foundation Models and Aligning for Generic Visual-Linguistic Tasks. CVPR 2024, arXiv:2312.14238.

[13] Mehdi Cherti, Romain Beaumont, Ross Wightman, et al. (2023). Reproducible Scaling Laws for Contrastive Language-Image Learning. CVPR 2023, arXiv:2212.07143.